Motivación y alcance

Adam combina suavizado del gradiente con escalado adaptativo por coordenada.

Estudio reproducible en C++17 con funciones analíticas deterministas.

Alcance: describir configuraciones ejecutadas; no afirmar superioridad universal.

Cómo actualiza Adam

$$m_t = \beta_1 m_{(t-1)} + (1-\beta_1) g_t$$
$$v_t = \beta_2 v_{(t-1)} + (1-\beta_2) g_t^2$$

Corrección de sesgo: $\hat{m}_t = m_t/(1-\beta_1^t)$, $\hat{v}_t = v_t/(1-\beta_2^t)$

$$\theta_{(t+1)} = \theta_t - \alpha\, \hat{m}_t / (\sqrt{\hat{v}_t} + \varepsilon)$$

Epsilon fuera de la raíz; operaciones elemento a elemento.

Implementación C++ y comprobaciones

Vectores de parámetros, primer momento y segundo momento.

Adam, Momentum y AMSGrad comparten funciones objetivo y registro.

Validación: parámetros, dimensiones, finitud numérica, ecuaciones en puntos conocidos.

CTest: 1/1 pasa.

Diseño experimental

Cuadrática: 2D y 10D
Rosenbrock: inicio (−1.5, 2), mínimo (1,1)
Rastrigin: inicio (2.5,2.5), mínimo global (0,0)
Reddi: secuencia periódica de gradientes

Mismos inicios, topes y tolerancia dentro de cada función. Tasas declaradas, no afinadas con presupues

Cuadrática y Rosenbrock

Iteraciones hasta la tolerancia del gradiente

Cuadrática 2D (1e−8): Adam 2619 · Momentum 339 · AMSGrad 1639
Rosenbrock (1e−6): Adam 4443 · Momentum 3118 · AMSGrad 16057

Cada resultado depende de la tasa configurada.

Rastrigin: estacionario no significa global

Rastrigin desde (2.5,2.5): gradiente pequeño para todos.

Objetivo final: Adam ≈ 7.96 · Momentum ≈ 1.99 · AMSGrad ≈ 7.96

El mínimo global conocido vale 0; los tres quedaron en mínimos locales.

Ejemplo periódico de Reddi

Después de 300,000 pasos: Adam $x \approx 0.9454$; AMSGrad $x \approx -0.9982$.

Óptimo de referencia: $x = -1$.

Evidencia de distinta conducta en esta construcción e hiperparámetros; no garantía general.

Complejidad y limitaciones

Con gradiente disponible: tiempo por actualización O(d).
Memoria auxiliar: Momentum O(d), Adam O(d), AMSGrad O(d).

El cálculo del gradiente cuesta aparte. Tiempos medidos una sola vez; no son benchmark estadístico. F

Conclusiones y siguientes pasos

La implementación vectorial en C++ y la batería son reproducibles.

Gradiente pequeño puede dejar un mínimo local. El ejemplo de Reddi separa las variantes probadas.

El artículo actual es borrador de 4 páginas: faltan 12–15 páginas finales, enlaces reales y grabación.